

Machine Learning Assignment-2 Report

Maedeh Abbasi - 401222094

#مقدمه:

در این پروژه، هدف ساخت یک مدل یادگیری ماشین برای طبقه‌بندی وضعیت سلامت روان افراد بر اساس ویژگی‌های دموگرافیک، سبک زندگی و شرایط شغلی/تحصیلی است. با توجه به ماهیت حساس این مسئله و احتمال عدم تعادل کلاس‌ها، چند مدل طبقه‌بندی مختلف آموزش داده شد و عملکرد آن‌ها با استفاده از معیارهای مختلف ارزیابی گردید.

#معرفی داده‌ها:

مجموعه داده مورد استفاده شامل اطلاعات نظرسنجی سلامت روان است که ویژگی‌هایی درباره وضعیت فردی، تحصیلی یا شغلی، عادات سبک زندگی و شاخص‌های مرتبط با سلامت روان را در بر می‌گیرد. یک بررسی اولیه از مجموعه داده با استفاده از `shape()`، `info()` و `describe()` انجام شد تا ابعاد داده، نوع داده‌ها و آمار خلاصه را درک کنیم. این مجموعه داده شامل متغیرهای عددی و دسته‌ای است که نیاز به پیش‌پردازش مناسب قبل از آموزش مدل دارد.

دیتاست شامل 140700 نمونه داده و 20 نوع ویژگی است. (10 نوع ویژگی عددی و 10 نوع ویژگی دسته‌ای)

*تحلیل متغیر هدف:

توزیع متغیر هدف نشان می‌دهد که مجموعه داده نامتعادل است. اکثریت مشاهدات متعلق به کلاس غیر افسرده هستند، در حالی که نسبت کمتری متعلق به کلاس افسرده است.

این عدم تعادل مهم است زیرا accuracy به تنهایی ممکن است ارزیابی نادرستی از عملکرد مدل ارائه دهد. بنابراین، معیارهای اضافی مانند Precision ، Recall ، F1-score ، ROC-AUC و PR-AUC در طول تحلیل مورد توجه قرار خواهند گرفت.

توجه خاصی به Recall برای کلاس افسردگی خواهد شد زیرا نادیده گرفتن شناسایی یک فرد واقعاً افسرده ممکن است عواقب جدی داشته باشد.

#پاک سازی و پیش پردازش داده ها:

*تحلیل مقادیر گمشده:

چندین متغیر شامل مقادیر گمشده هستند. بررسی مجموعه داده نشان می دهد که بسیاری از این مقادیر گمشده ساختاری هستند تا تصادفی. برای مثال، متغیرهای مرتبط با زندگی تحصیلی (مانند CGPA و فشار تحصیلی) عمدتاً برای دانشجویان مربوط هستند، در حالی که متغیرهای مرتبط با اشتغال (مانند فشار کاری و رضایت شغلی) عمدتاً برای حرفه ای های شاغل مربوط می شوند. بنابراین، خود فقدان ، اطلاعاتی درباره وضعیت فرد دارد.

*بررسی ویژگی های عددی:

متغیرهای عددی با استفاده از هیستوگرام ها و نمودارهای جعبه ای بررسی شدند. این تجسم ها بینش هایی درباره توزیع ها، تمایل های احتمالی و وجود نقاط دورافتاده ارائه می دهند. مقایسه ها در میان کلاس های افسردگی نشان می دهد که متغیرهایی مانند فشار مالی، فشار تحصیلی و فشار کاری تمایل دارند توزیع های متفاوتی بین افراد افسرده و غیر افسرده نشان دهند. این مشاهدات نشان می دهند که چنین متغیرهایی ممکن است به طور قابل توجهی به عملکرد پیش بینی کمک کنند و باید در طول توسعه مدل حفظ شوند.

* بررسی ویژگی‌های دسته‌ای:

متغیرهای دسته‌ای برای بررسی ارتباط آن‌ها با وضعیت افسردگی تحلیل شدند. چندین دسته به نظر می‌رسد که نرخ‌های متفاوت افسردگی را نشان می‌دهند. متغیرهای مرتبط با سبک زندگی، تحصیلات، شغل و تاریخچه سلامت روان اطلاعات پیش‌بینی‌کننده‌ای داشتند. مثلاً بیش از نصف افرادی که محصل بودند دچار افسردگی نشان داده شدند درحالی‌که این درصد در بین شاغلان بسیار پایین‌تر بود.

* حذف ویژگی‌های غیرمفید:

متغیرهای `id` و `Name` قبل از آموزش مدل از مجموعه داده‌ها حذف شدند. متغیر `id` تنها به عنوان یک شناسه منحصر به فرد عمل می‌کند و اطلاعات پیش‌بینی‌کننده‌ای ندارد. به همین ترتیب، متغیر `Name` افراد را به طور منحصر به فرد شناسایی می‌کند و انتظار نمی‌رود که رابطه معناداری با وضعیت افسردگی داشته باشد. نگهداری از چنین متغیرهایی ممکن است نویز غیرضروری را معرفی کرده و پیچیدگی مدل را افزایش دهد بدون اینکه عملکرد پیش‌بینی را بهبود بخشد.

* پیش‌پردازش داده:

یک pipeline پیش‌پردازش ایجاد شد تا اطمینان حاصل شود که تمام تغییرات به طور مداوم اعمال می‌شوند و نشت داده‌ای ایجاد نمی‌شود.

متغیرهای عددی با استفاده از میانه پر شده و سپس استانداردسازی شدند. متغیرهای دسته‌ای با استفاده از پر تکرارترین دسته پر شده و با استفاده از کدگذاری One-Hot رمزگذاری شدند.

مراحل پیش‌پردازش در یک پایپ لاین scikit-learn و ColumnTransformer ادغام شدند تا تمام عملیات به طور انحصاری بر روی داده‌های آموزشی در حین اعتبارسنجی متقابل و ارزیابی مدل اجرا شوند.

#Baseline Model:

به عنوان یک baseline، از Dummy Classifier استفاده شد. نتایج این مدل نشان داد که با وجود دستیابی به دقت کلی برابر با 0.82، عملکرد آن بر روی کلاس اقلیت بسیار ضعیف بود؛ به طوری که precision، recall و F1-score برای کلاس 1 همگی برابر با صفر شدند. این موضوع بیانگر عدم تعادل شدید کلاس‌ها در دیتاست و ناکافی بودن Accuracy به تنهایی برای ارزیابی مدل است. از این رو، در ادامه از معیارهایی مانند macro F1 score و ROC-AUC نیز برای ارزیابی مدل‌ها استفاده شد.

#Logistic Regression:

رگرسیون لجستیک به طور قابل توجهی از baseline classifier در تمام معیارهای ارزیابی بهتر عمل کرد. این مدل به accuracy کلی تقریباً 91% دست یافت که نشان‌دهنده عملکرد پیش‌بینی قوی در مجموعه تست است.

مهم‌تر از همه، مدل به Recall 92% برای کلاس افسردگی دست یافت، به این معنی که اکثریت قریب به اتفاق افراد افسرده به درستی شناسایی شدند. این نتیجه‌ای مهم است زیرا نادیده گرفتن افسردگی ممکن است عواقب بالینی جدی داشته باشد.

ماتریس (confusion matrix) تنها 385 نمونه FN (false negative) را نشان داد که نشان می‌دهد نسبتاً تعداد کمی از افراد افسرده نادیده گرفته شدند. اگرچه مدل 2008 FP (false positive) تولید کرد، چنین خطاهایی ممکن است در یک زمینه غربالگری نسبت به موارد مثبت نادیده گرفته شده قابل قبول‌تر باشند. علاوه بر این، مدل به امتیاز $ROC-AUC = 0.973$ دست یافت که نشان‌دهنده تمایز عالی بین افراد افسرده و غیر افسرده است. به طور کلی، رگرسیون لجستیک تعادل قوی بین دقت پیش‌بینی و حساسیت برای شناسایی افسردگی ارائه می‌دهد.

#Random Forest

Random forest classifier به accuracy کلی تقریباً 91% و امتیاز $ROC-AUC = 0.96$ دست یافت که نشان‌دهنده توانایی تمایز قوی است.

در مقایسه با رگرسیون لجستیک، مدل precision بالاتری (0.84) را به دست آورد که نشان می‌دهد پیش‌بینی‌های مثبت احتمالاً صحیح‌تر بودند. با این حال، Recall برای کلاس افسردگی به طور قابل توجهی به تقریباً 62.5% کاهش یافت.

این کاهش در Recall نشان می‌دهد که تعداد بیشتری از افراد افسرده توسط مدل نادیده گرفته شدند. در یک زمینه غربالگری سلامت روان، چنین FN(false negative) هایی ممکن است نامطلوب باشند زیرا افرادی که به حمایت نیاز دارند ممکن است شناسایی نشوند.

اگرچه جنگل تصادفی عملکرد کلی رقابتی را نشان داد، رگرسیون لجستیک حساسیت به مراتب بالاتری برای شناسایی افسردگی ارائه داد و بنابراین ممکن است برای اهداف غربالگری ترجیح داده شود.

#Threshold tuning:

رگرسیون لجستیک برآوردهای احتمالی برای هر مشاهده تولید می‌کند. به طور پیش‌فرض، مشاهداتی که دارای احتمال پیش‌بینی شده بالاتر از 0.5 هستند به عنوان مثبت طبقه‌بندی می‌شوند.

برای بررسی تعادل بین precision و recall، چندین classification thresholds ارزیابی شد. آستانه‌های پایین‌تر recall را با شناسایی افراد افسرده بالقوه بیشتر افزایش دادند، در حالی که آستانه‌های بالاتر precision را افزایش دادند اما به هزینه نادیده گرفتن موارد مثبت بیشتر.

با توجه به ماهیت غربالگری مسئله، recall بالاتر ممکن است ترجیح داده شود زیرا نادیده گرفتن یک فرد افسرده به طور کلی هزینه‌برتر از تولید FP(false positive) های اضافی است.

بنابراین، آستانه 0.4 به عنوان یک سازش معقول در نظر گرفته شد که recall تقریباً 94% را به دست آورد در حالی که precision قابل قبولی را حفظ کرد.

#XGBoost:

نتایج حاصل از مدل XGBoost نشان می‌دهد که پیاده‌سازی صحیح Pipeline پیش‌پردازش در کنار تنظیم هوشمندانه ابرپارامترها، توانست چالش عدم تعادل کلاس‌ها را به‌طور مؤثری رفع نماید. دستیابی به-F1 score بالغ بر 0.82 و ROC-AUC نزدیک به 0.97، تاییدی بر پایداری و دقت بالای مدل نهایی در پیش‌بینی وضعیت سلامت روان افراد است.

Model Comparison and Final Model Selection:

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Dummy	0.82	0.00	0.00	0.00	-
Logistic Regression (0.5)	0.91	0.70	0.925	0.798	0.973
Logistic Regression (0.4)	-	0.658	0.940	0.774	0.973
Random Forest	0.910	0.837	0.625	0.716	0.960
XGBoost	0.939	0.843	0.814	0.828	0.974

*Logistic Regression

مزیت:

- Recall بسیار بالا (92.5% تا 94%)
- تعداد False Negative کم
- تفسیرپذیری بالا

عیب:

- Precision پایین‌تر

*Random Forest

مزیت:

- Precision خوب

عیب:

- Recall بسیار پایین‌تر (62.5%)
- برای غربالگری سلامت روان مناسب نیست

*XGBoost

مزایا:

- بهترین Accuracy
- بهترین F1

- بهترین ROC-AUC
- Precision بالا
- Recall خوب (81%)

#انتخاب مدل نهایی:

سه مدل یادگیری ماشین برای پیش‌بینی افسردگی ارزیابی شدند: رگرسیون لجستیک، Random forest و XGBoost.

Random forest دقت رقابتی را به دست آورد اما recall به طور قابل توجهی کمتری برای کلاس افسردگی نشان داد که آن را برای یک کاربرد غربالگری که در آن نادیده گرفتن موارد مثبت هزینه‌بر است، کمتر مناسب می‌سازد.

رگرسیون لجستیک بالاترین recall را به دست آورد و بیش از 92% از افراد افسرده را به درستی شناسایی کرد. این ویژگی به ویژه در غربالگری سلامت روان ارزشمند است زیرا FN(false negative) ها ممکن است مانع از دریافت حمایت به موقع افراد شوند.

XGBoost بهترین عملکرد پیش‌بینی کلی را به دست آورد و بالاترین دقت (93.9%)، امتیاز F1 (0.828) و ROC-AUC (0.974) را کسب کرد. با این حال، recall آن کمتر از رگرسیون لجستیک بود.

*ارزیابی نهایی مدل

*Confusion Matrix(for logistic regression):

واقعی / پیش‌بینی شده		افسردگی افسردگی	
		بدون افسردگی	افسردگی
بدون افسردگی	پیش‌بینی شده بدون افسردگی	21,019	2,008
	پیش‌بینی شده افسردگی		

| افسردگی | 385 | 4,728 |

این ماتریس نشان می‌دهد که مدل به درستی 4,728 فرد افسرده را شناسایی کرده در حالی که تنها 385 مورد را از دست داده است. اگرچه 2,008 فرد غیر افسرده به اشتباه به عنوان افسرده طبقه‌بندی شده‌اند، اما تعداد موارد مثبت از دست رفته نسبتاً کم باقی مانده است.

*Classification Report:

معیار	بدون افسردگی	افسردگی
	-----	-----
accuracy	0.98	0.70
recall	0.91	0.92
F1-score	0.95	0.80

دقت کلی = 91%

ROC-AUC = 0.973

*ROC Curve:

منحنی ROC تعادل بین نرخ TP (recall) و نرخ FP را در آستانه‌های مختلف طبقه‌بندی نشان می‌دهد. مدل امتیاز ROC-AUC برابر با 0.973 را به دست آورد که نشان‌دهنده تمایز عالی بین افراد افسرده و غیر افسرده است.

*نقاط قوت:

نقطه قوت اصلی مدل رگرسیون لجستیک، recall بالای آن برای کلاس افسردگی (92%) است. این به این معناست که مدل به طور موفقیت‌آمیزی اکثریت قریب به اتفاق افرادی را که دچار افسردگی هستند شناسایی می‌کند.

این مدل همچنین امتیاز ROC-AUC بالایی (0.973) را به دست آورد که نشان‌دهنده توانایی تمایز کلی قوی است. علاوه بر این، رگرسیون لجستیک از نظر محاسباتی کارآمد، قابل تفسیر و نسبت به مدل‌های پیچیده‌تر نسبتاً مقاوم در برابر overfitting است.

*نقاط ضعف:

این مدل تعداد متوسطی از پیش‌بینی‌های FP (false positive) را تولید می‌کند که منجر به $\text{precision} = 70\%$ برای کلاس افسردگی می‌شود. در نتیجه، برخی افراد ممکن است به اشتباه به عنوان افراد بالقوه افسرده شناسایی شوند.

اگرچه این ممکن است هزینه‌های غربالگری پیگیری را افزایش دهد، اما این نوع خطاها معمولاً کمتر جدی در نظر گرفته می‌شوند نسبت به نادیده گرفتن افرادی که واقعاً به حمایت نیاز دارند.

*تفسیر:

برای یک برنامه غربالگری سلامت روان، نادیده گرفتن یک فرد افسرده (FN) هزینه‌بر تر از به اشتباه شناسایی یک فرد غیر افسرده (FP) است. بنابراین، recall بالایی که رگرسیون لجستیک به دست آورده، آن را به ویژه برای این کار مناسب می‌سازد.

اگرچه XGBoost دقت کلی (accuracy) و F1-score کمی بالاتری به دست آورد، رگرسیون لجستیک انتخاب شد زیرا حساسیت بسیار بالاتری برای شناسایی افسردگی ارائه می‌دهد که با اهداف یک سیستم غربالگری هم‌راستا است.

#تفسیر مدل:

مدل رگرسیون لجستیک ضرایب قابل تفسیر ارائه می‌دهد که نشان‌دهنده جهت و قدرت نسبی ارتباط بین پیش‌بین‌ها و افسردگی است.

در میان تمام پیش‌بین‌ها، سن بزرگترین ضریب مطلق را نشان داد. ضریب منفی نشان می‌دهد که افراد مسن‌تر کمتر احتمال دارد که پس از کنترل سایر متغیرها در مدل به عنوان افسرده طبقه‌بندی شوند.

افکار خودکشی به عنوان یکی از قوی‌ترین پیش‌بین‌های افسردگی ظهور کرد. افرادی که افکار خودکشی را گزارش کردند، احتمال بسیار بالاتری برای افسردگی داشتند، در حالی که عدم وجود افکار خودکشی به شدت با کاهش ریسک افسردگی مرتبط بود. این یافته با تحلیل اکتشافی و ادبیات روان‌شناختی موجود هم‌راستا است.

فشار کاری و استرس مالی نیز به عنوان پیش‌بین‌های مثبت مهم شناخته شدند. سطوح بالاتر فشار شغلی و مشکلات مالی با افزایش احتمال افسردگی مرتبط بودند.

مدل همچنین نشان داد که وضعیت دانشجویی با احتمال بالاتری برای افسردگی مرتبط است، در حالی که بودن به عنوان یک حرفه‌ای شاغل با احتمال کمتری برای افسردگی مرتبط بود. این نتیجه با تحلیل اکتشافی هم‌خوانی دارد که شیوع افسردگی را در میان دانشجویان به طور قابل توجهی بالاتر نشان داد.

چندین دسته مرتبط با حرفه نیز در میان متغیرهای تأثیرگذارترین ظاهر شدند که نشان می‌دهد زمینه شغلی ممکن است به نتایج سلامت روان کمک کند. با این حال، این اثرات باید با احتیاط تفسیر شوند زیرا برخی از دسته‌های شغلی ممکن است مشاهدات کمتری نسبت به دیگران داشته باشند.

عادات غذایی سالم و رضایت شغلی با کاهش ریسک افسردگی مرتبط بودند، که نشان می‌دهد سبک زندگی و رفاه در محل کار ممکن است نقش‌های حمایتی ایفا کنند.

به طور کلی، مدل رگرسیون لجستیک سن، افکار خودکشی، وضعیت دانشجویی، فشار کاری، استرس مالی، عادات غذایی و رضایت شغلی را به عنوان برخی از تأثیرگذارترین پیش‌بین‌های افسردگی درون مجموعه داده‌ها برجسته می‌کند.

